

# Azure OpenAl's API



#### **Michele Aponte**

CEO&CTO @ Ellycode / CEO @ Blexin / CTO @ Improove Skills Founder @ Blazor Developer Italiani / MVP Developer Technologies & AI















**Deltatre** Innovation Lob





# Che cos'é OpenAl?



Avrete sicuramente sentito parlare almeno di ChatGPT....





#### Modelli di Generative Al

### **Artificial Intelligence**

Machine Learning

Deep Learning

Generative Al





# "Azure" OpenAl

Microsoft ha una **partnership** con OpenAl per fornire questo servizio tramite Azure a livello enterprise:

- · Possiamo utilizzare l'infrastruttura di Azure, quindi **security, compliance** e la disponibilità da **diverse Region**.
- · Usare i modelli OpenAl attraverso prodotti Microsoft come **Azure Al**.
- · Sfruttare tutta la potenza dei workloads OpenAl







# "Azure" OpenAl

Azure OpenAI è composta da 4 componenti principali:

- · Modelli Generative Al già pronti
- Possibilità di personalizzare i modelli attraverso l'operazione di fine-tune con i propri dati
- Strumenti di controllo per implementare un uso responsabile dei modelli
- Enterprise-grade security con role-based access control (RBAC) e private networks





# Cosa possiamo fare

#### Possiamo fare 3 categorie di cose:

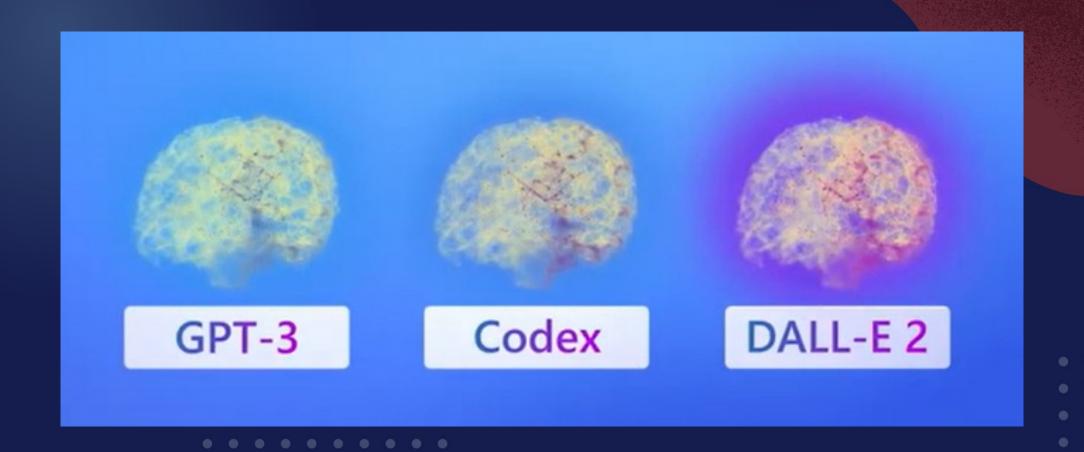
- · Generare contenuti in Linguaggio Naturale
  - · Text completion: generare e editare testo
  - · Ricerca, classificazione e comparazione di testo
- Generare, editare e analizzare codice (in tantissimi linguaggi)
- · Generare e editare immagini







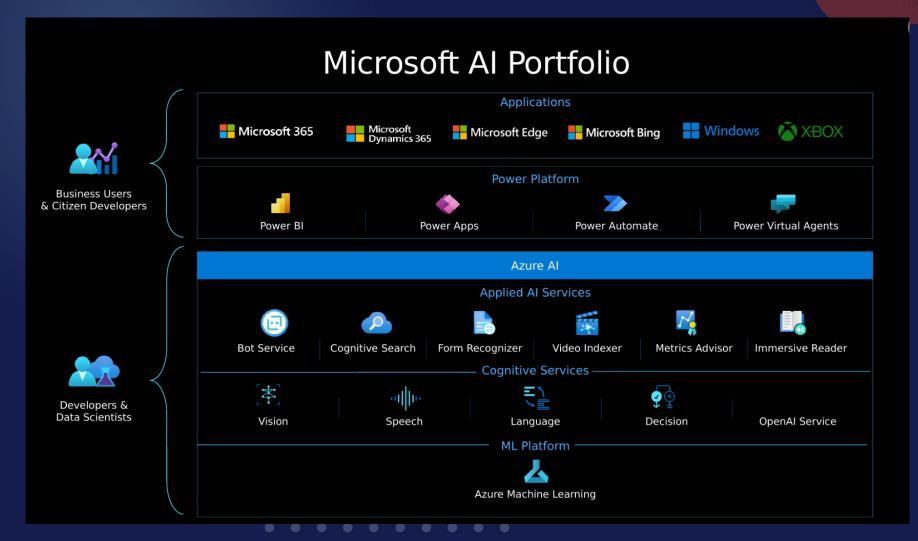
# Modelli OpenAl





**Deltatre**Innovation
Lab

# Azure OpenAl's negli Azure Al services









Al momento è necessario **richiedere l'accesso** a Azure OpenAl compilando un form. Una volta avuto l'accesso:

- Creare la risorsa su Azure
- **Eseguire il deploy** di uno o più modelli (esistenti o personalizzati) utilizzando **Azure OpenAl Studio**









Cognitive Services | Azure OpenAl Studio - Preview

Azure OpenAl Studio

Privacy & cookies

#### Get started with Azure OpenAl

Perform a wide variety of natural language tasks with Azure OpenAI, including copywriting, summarization, parsing unstructured text, classification, and translation.

#### Explore examples for prompt completion



#### **Summarize Text**

Summarize text by adding a 'tl;dr:' to the end of a text passage.

Learn more



#### **Classify Text**

Classify items into categories provided at inference time.

Learn more



#### Natural Language to SQL

Translate natural language to SQL queries.

Learn more

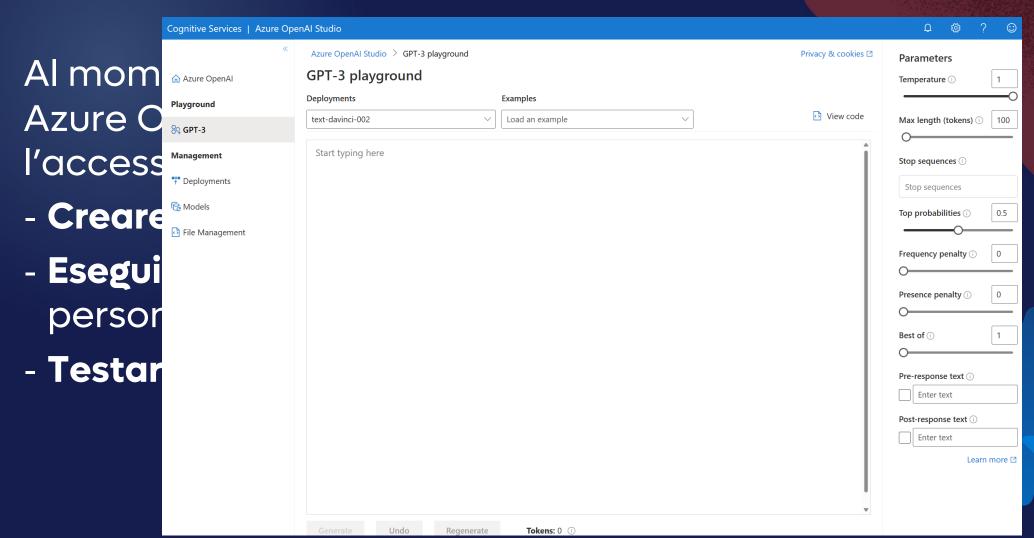


#### **Generate New Product Names**

Create product names from examples words.

Learn more











Al momento è necessario **richiedere l'accesso** a Azure OpenAl compilando un form. Una volta avuto l'accesso:

- Creare la risorsa su Azure
- **Eseguire il deploy** di uno o più modelli (esistenti o personalizzati) utilizzando **Azure OpenAl Studio**
- Testare il modello nel Playground
- Utilizzare il servizio mediante libreria Python o chiamata REST (no NuGet al momento 😊)









### **DEMO 1**

Creare un risorsa OpenAl



Deltatre Innovation Lab



# I modelli OpenAl di linguaggio naturale

I modelli Azure OpenAI capiscono il linguaggio naturale e forniscono risposte in linguaggio naturale:

- I modelli sono addestrati su parole o blocchi di caratteri chiamati tokens.
- Per esempio la parola **hamburger** viene spezzata nei tokens **ham**, **bur**, e **ger**, mentre una parola come **pera** è un singolo token.
- Questi tokens sono **mappati in vettori** usati per addestrare un modello di machine learning.
- Quando questi modelli ricevono una richiesta, il testo passato come parametro viene spezzato in tokens.





# Modelli GPT per la generazione del linguaggio naturale

I modelli **G**enerative **p**re-trained **t**ransformer (**GPT**) sono bravissimi sia a comprendere che a generare linguaggio naturale:

- I modelli GPT **sono numerati** in base alla versione, **GPT-2** o **GPT-3** ad esempio.
- **Azure OpenAl offre l'accesso a GPT-3** e presto supporterà GPT-3.5.





# Cosa può fare un modello GPT-3?

Dato un testo in input, chiamato **prompt**, GPT prova a inferire, o indovinare, il contesto della domanda. Gli possiamo chiedere di:

- Eseguire la sintesi di un testo (summarizing)
- Classificare un contenuto
- Generare nomi o frasi a partire da una descrizione
- Tradurre testi
- Rispondere a domande
- Suggerire contenuti







### **DEMO 2**

Usare il playground per generare contenuti









# Generazione di codice con OpenAl

E' possible chiedere, in linguaggio naturale, a un modello OpenAl anche di **generare del codice**:

- Questa famiglia di modelli è chiamata Codex e funziona con tantissimi linguaggi come C#, JavaScript, Perl, PHP, Python
- Un esempio molto valido è GitHub Copilot, nato dalla collaborazione tra GitHub e OpenAI, un assistente nella scrittura del codice fornito come plugin in Visual Studio Code



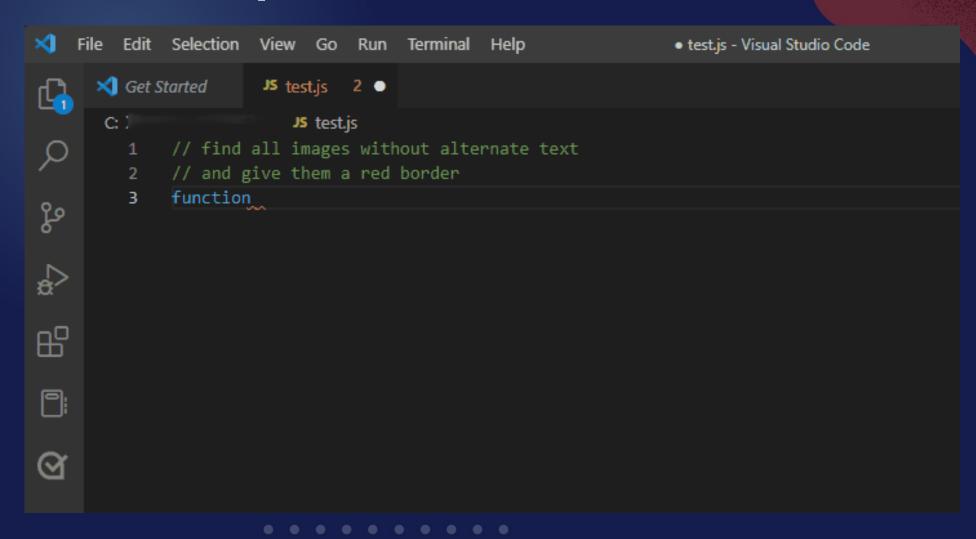


# GitHub Copilot



Deltatre Innovation Lab

# GitHub Copilot







### **DEMO 3**

Usare il playground per generare codice









# Generare immagini con i modelli OpenAl

E' possibile generare o editare immagini a partire da una richiesta in linguaggio naturale:

- Questa tipologia di modello si chiama DALL-E, e anche in questo caso il nome è seguito dal numero di versione, ad esempio DALL-E 2
- **L'accesso** a questi modelli al momento **é solo su invito** (sono ancora in attesa ⊗), ma possiamo farci una idea del suo funzionamento





# Generare una immagine da un testo

"an elephant standing with a burger on top, style digital art"









# Generare una immagine da un testo

"a pink fox"







# Generare una immagine da un testo

"a pink fox running through a field, in the style of Monet"

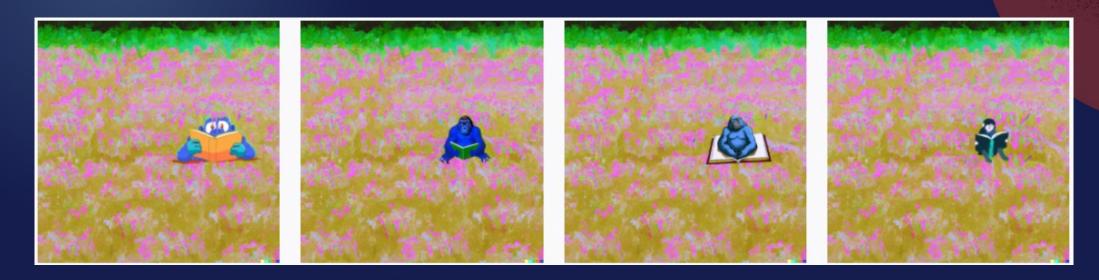






# Modificare una immagine

"blue gorilla reading a book in a field"







# Accesso alle API di Azure OpenAI

Come tutti i servizi Azure, possiamo accedere a Azure OpenAl utilizzando delle API REST. Ci servono:

- Un client HTTP nel linguaggio scelto
- L'endpoint del servizio (https://<nome>.openai.azure.com/)
- **Nome** che abbiamo dato al **deploy** che abbiamo fatto e che vogliamo utilizzare
- Una delle due **key** della risorsa





# Accesso alle API di Azure OpenAI

#### A questo punto ci basta:

- Eseguire una **POST HTTP** all'endpoint così costruito:
  - endpoint + "openai/deployments/" + nome\_deploy + "completions?apiversion=2022-12-01"
- Aggiungere un header HTTP "api-key" con la key della risorsa
- Passare nel body della Request almeno la proprietà "prompt"
- Eseguire il **parsing della risposta JSON** per recuperare le informazioni fornite dal servizio





### **DEMO 4**

Costruiamo il nostro playground utilizzando C# e Blazor









# Personalizzare i modelli OpenAl

I modelli Azure OpenAI, al pari di molti Cognitive Services, possono essere personalizzati eseguendo il cosiddetto finetuning:

- Questo ci permette di utilizzare i nostri dati per addestrare i modelli
- E' molto importante **verificare i risultati prodotti** da questo tipo di modelli
- I modelli di Azure OpenAI sono addestrati con dati che arrivano fino a
   Ottobre 2019, quindi non contengono informazioni successive a quella
   data.
- https://learn.microsoft.com/en-us/azure/cognitiveservices/openai/how-to/fine-tuning





# Quanto mi costi?

Pricing details:				
Instance	Series	Models	Inferencing per 1,000 tokens	Hosting per hour
Standard	Base Series	Ada Babbage Curie Davinci	€0.000369 €0.000462 €0.001845 €0.018450	N/A N/A N/A
	Base Series Fine-tuned	Ada Babbage Curie Davinci	€0.000369 €0.000462 €0.001845 €0.018450	€0.0462 €0.0738 €0.2214 €31.3639
	Codex Series	Code-Cushman Code-Davinci	€0.022140 €0.092247	N/A N/A
	Codex Series Fine-tuned	Code-Cushman	€0.022140	€0.4982/hour
	Embeddings	Ada Babbage Curie Davinci	€0.003690 €0.004613 €0.018450 €0.184494	N/A N/A N/A





# Accesso limitato a Azure OpenAl

Una delle ragioni per le quali l'accesso a Azure OpenAl è attualmente limitato e garantire un uso etico e controllato di questi servizi:

- Bisogna sottomettere una richiesta sia per sperimentare con il servizio sia per usarla in produzione, spiegando il caso d'uso che si vuole implementare.
- E' richiesta una ulteriore registrazione per accedere ai tool di content filters e abuse monitoring.





# Takeaways

- Possiamo dare valore alle nostre applicazioni con la potenza dei modelli OpenAl
- Se **utilizziamo** già **Azure** possiamo sfruttare tutto quello che già conosciamo per dare robustezza agli **scenari enterprise**
- Possiamo facilmente integrare i servizi Azure OpenAl con un semplice client HTTP (in attesa di un pacchetto NuGet ufficiale)
- Occhio ai costi e alla "degenerazione" che può avere l'uso di questi servizi, l'approccio alla AI deve essere sempre responsabile!





#### Link utili

- Percorso Learn: <a href="https://learn.microsoft.com/en-us/training/modules/explore-azure-openai/">https://learn.microsoft.com/en-us/training/modules/explore-azure-openai/</a>
- Documentazione ufficiale: <a href="https://learn.microsoft.com/enus/azure/cognitive-services/openai/">https://learn.microsoft.com/enus/azure/cognitive-services/openai/</a>
- Reference API: <a href="https://learn.microsoft.com/en-us/azure/cognitive-">https://learn.microsoft.com/en-us/azure/cognitive-</a>
  <a href="mailto:services/openai/reference#management-apis">services/openai/reference#management-apis</a>





### **Questions & Answers**



#### **Michele Aponte**

CEO&CTO @ Ellycode / CEO @ Blexin / CTO @ Improove Skills Founder @ Blazor Developer Italiani / MVP Developer Technologies & Al







apomic80



apomic80





**Deltatre** Innovation Lob

